

Baseline Tabular para Intercepción de Balón en RoboCup 2D

Fase 1 (P1)

Grupo: BlueLock

Integrantes:

Hans Mendoza

Luis Jáuregui

Repositorio: https://github.com/Alaprexian/Robocup_RL2026-2

Resumen

Se aborda la intercepción de balón en RoboCup 2D como MDP tabular con observaciones polares discretizadas ($|\mathcal{S}| = 20$, $|\mathcal{A}| = 4$). Se implementan Monte Carlo Control On-Policy (First-Visit) y Q-Learning, comparando exploración ε -greedy fija ($\varepsilon = 0,1$) frente a decaimiento geométrico. En 3500 episodios sobre un proxy cinemático, Q-Learning alcanza tasa de éxito final del 100 % (últimos 100 episodios) con retorno medio ≈ 143 y ≈ 27 pasos; MC con ε fijo llega al 98 %, mientras que MC con ε decreciente desde 1,0 se queda en 16 %, evidenciando la sensibilidad del promedio first-visit a exploración prolongada.

1. Introducción y Descripción de la Tarea

La Fase 1 exige resolver una subtarea acotada antes de escalar a Deep RL. Seleccionamos **persecución/intercepción de balón**: el agente debe alcanzar $d_b < 0,8$ m (kickable area) desde posiciones aleatorias en su media cancha. El ruido perceptual y la dinámica de `rcssserver` se abordan en despliegue; el aprendizaje tabular se realiza en un entorno cinemático reproducible ($|\mathcal{A}|$ macros, horizonte 80) compatible con el cliente UDP del starter kit.

2. Modelado Formal como MDP

Tupla $\langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle$:

- **Estados ($\mathcal{S}$):** observación polar (d_b, θ_b) discretizada en 4 bins de distancia $\times$ 5 de ángulo $\Rightarrow |\mathcal{S}| = 20$.
 - Distancia: $< 0,8$, $[0,8, 3)$, $[3, 8)$, ≥ 8 m.
 - Ángulo: frontal $|\theta| \leq 15^\circ$; der./izq. frontal $\pm[15, 60]$; posteriores.

- **Acciones ($\mathcal{A}$):** DASH 100, DASH 50, TURN $+35^\circ$, TURN -35° ($|\mathcal{A}| = 4$).
- **Transiciones ($\mathcal{P}$):** en el proxy, cinemática determinista; en `rcssserver`, dinámica estocástica con fricción y ruido sensorial.
- **Recompensa ($\mathcal{R}$):**

$$R = \begin{cases} +100 & d_b < 0,8 \\ -20 & \text{timeout} \\ -1 + 5\Delta d & \text{en otro caso} \end{cases}$$
- **Descuento y horizonte:** $\gamma = 0,99$, $T_{\text{máx}} = 80$. Tabla Q : $|\mathcal{S}| \cdot |\mathcal{A}| = 80$ pares.

2.1. Justificación analítica de la discretización

El umbral 0,8 m es el radio de kickable area del servidor oficial, por lo que el bin 0 corresponde al estado terminal de éxito. Los cortes 3 m y 8 m separan zonas donde un dash fuerte reduce materialmente la distancia en pocos pasos frente a distancias que requieren primero alinear el cuerpo. El cono $\pm 15^\circ$ concentra políticas de avance; $\pm 60^\circ$ distingue giros parciales de giros de búsqueda. Con $|Q| = 80$, un presupuesto de 3500 episodios aporta del orden de decenas de visitas esperadas por par (s, a) bajo exploración moderada, lo que es compatible con métodos tabulares sin explosión combinatoria.

3. Algoritmos de Aprendizaje

- **Monte Carlo Control On-Policy (First-Visit):** tras cada episodio se actualiza $Q(s, a)$ con el promedio de retornos G_t en la primera visita a (s, a) .
- **Q-Learning (off-policy):** $Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)]$ con $\alpha = 0,1$ (terminal: target = r).
- **Exploración:** (i) ε fijo = 0,1; (ii) $\varepsilon_k = \max(0,05, 1,0 \cdot 0,998^k)$.

4. Resultados Experimentales

Cuatro configuraciones, semilla 42, 3500 episodios. Métricas en los últimos 100 episodios:

Configuración	Retorno G_0	Pasos	Éxito
MC + ε decay	-62,1	71,6	16 %
MC + ε fijo 0,1	136,2	30,7	98 %
QL + ε decay	142,8	26,6	100 %
QL + ε fijo 0,1	141,3	28,3	100 %

Tabla 1: Desempeño final (últimos 100 episodios).




Figura 1: Retorno suavizado, tasa de éxito temporal (ventana 50) y pasos por episodio.




Figura 2: Mapas de $V^*(s)$ y $\pi^*(s)$ para la mejor configuración (QL + ε decay).

5. Discusión

Q-Learning converge de forma estable bajo ambos esquemas de exploración: el bootstrap reduce la varianza frente al retorno Monte Carlo completo. MC con ε fijo aprende una política casi óptima (98 % de éxito), pero MC con decaimiento desde $\varepsilon_0 = 1$ acumula retornos fallidos early-episode en el promedio first-visit y no se recupera en el horizonte evaluado (16 % de éxito). Esto confirma el requisito del enunciado de comparar empíricamente ambas políticas de exploración. La discretización compacta permite visualizar π^* interpretable (girar hasta cono frontal, luego dash fuerte). Limitación: el proxy omite ruido de (**see**) y dinámica de estamina; la Fase 2 deberá transferir políticas a espacio continuo sobre el servidor real.

6. Conclusiones

Se cumplió el baseline tabular P1: MDP formal, discretización justificada, MC Control y Q-Learning, comparación ε fijo vs. decreciente, y análisis de G_0 , tasa de éxito y π^* . El mejor agente (Q-Learning) alcanza intercepción consistente. Próximos pasos (P2): DQN/PPO en estado continuo, reward shaping potencial (Ng et al., 1999) y despliegue competitivo o transferencia.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97*, Springer, 1998.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations,” in *ICML*, 1999.