

Baseline Tabular para Habilidades de Fútbol en RoboCup 2D

Fase 1 (P1): catálogo de tareas acotadas

Grupo BlueLock

Hans Mendoza · Luis Jáuregui

https://github.com/Alaprexian/Robocup_RL2026-2

Resumen

En lugar de abordar directamente un partido 11 vs 11, el enunciado propone comenzar por habilidades individuales. Modelamos las cuatro tareas del catálogo—persecución, drible, tiro y pase 2v1—como MDPs tabulares sobre un proxy cinemático, con discretización polar alineada al radio kickable de `rcssserver`, y comparamos Monte Carlo Control y Q-Learning bajo ε fijo frente a ε decreciente (3500 episodios por configuración). Tras ajustar el tiro (alineación multi-paso) y el pase (recompensa anclada a posesión), las cuatro tareas alcanzan los criterios de éxito del enunciado en su mejor configuración.

1. Por qué este problema y cómo lo atacamos

RoboCup 2D es un POMDP ruidoso y competitivo: aprender “jugar fútbol” de cero con métodos tabulares hace explotar el espacio. El curso propone aislar subtareas controlables, visualizar qué aprende el agente y recién después escalar a Deep RL.

Trabajamos en Python dentro del stack Docker del starter kit, con entornos en `src/envs/` que imitan dash, giro, kick y pase sin pagar el costo de `rcssserver` en cada update de Q . El proxy no reemplaza al servidor oficial (sigue siendo el destino de despliegue), pero permite experimentos reproducibles (semilla 42) y comparación justa entre algoritmos. Los agentes (`src/agents/`) son agnósticos al tamaño de $\mathcal{A}$: leen `env.n_actions` y guardan Q indexada por estados hashables.

2. Discretización y formalización de las tareas

En todas usamos $\gamma = 0,99$ y políticas ε -greedy.

2.1. Discretización polar

Para que $Q(s, a)$ sea tabular, convertimos observaciones continuas (distancia y ángulo relativo) en *bins*. El esquema compartido vive en `src/discretizer.py` y replica convenciones de RoboCup 2D:

Las tuplas de estado discretas que indexan $Q(s, a)$ en cada tarea son:

Bin	Rango / significado	Motivación
Dist. 0	$d < 0,8$ m	Radio kickable de rcssserver
Dist. 1	$[0,8, 3)$ m	Reacción cercana
Dist. 2	$[3, 8)$ m	Media
Dist. 3	$d \geq 8$ m	Lejana
Áng. 0	$ \theta \leq 15^\circ$	Cono frontal de dash efectivo
Áng. 1–2	hasta $\pm 60^\circ$	Giro parcial
Áng. 3–4	posterior	Giro completo

Tabla 1: Bins polares compartidos. En persecución pura: $|\mathcal{S}| = 4 \times 5 = 20$. Las demás tareas extienden el estado con bins adicionales (meta, portero, compañero, posesión).

Tarea	Tupla s	Componentes
Pursuit	(d_b, a_b)	Dist. y ángulo al balón (bins polares)
Dribbling	(d_b, a_b, d_g, a_g)	Balón + meta rival (bins)
Shooting	(d_g, b, g_k, f)	Dist. arco, sector corporal, bin GK, facing_ok
Passing	(d_c, a_c, d_d, a_d, h)	Compañero, defensor, posesión $h \in \{0, 1\}$

Tabla 2: Estado tabular por tarea (todos los campos son enteros de bins, salvo h binario).

2.2. Persecución e intercepción

El agente nace con $d_b \in [5, 40]$ m (enunciado) y orientación aleatoria. Estado $s = (d_b, a_b)$ con $|\mathcal{S}| = 20$; acciones: DASH fuerte/suave (+1,2 / +0,6 m) o giro $\pm 35^\circ$; horizonte $T_{\max} = 120$. La recompensa por paso combina costo temporal y *término de acercamiento*:

$$R_t = -1 + 5(d_{t-1} - d_t),$$

con terminal +100 si $d_b < 0,8$ m y -20 por timeout. Así se empuja a capturas cortas y se da señal densa cuando aún no hay gol de captura.

2.3. Drible

Estado $s = (d_b, a_b, d_g, a_g)$: relación al balón y a la meta rival, ambos discretizados. Acciones: micro-pateo, carrera y giros. Éxito: avance neto ≥ 30 m con posesión vigente; fallo si sale de cancha o pierde el balón varios pasos. Implementación: en dash cerca del balón, el proxy “pega” la pelota delante del jugador ($\approx 0,55$ m), aproximando posesión sin física completa de rebote.

2.4. Tiro a puerta

Estado $s = (d_g, b, g_k, f)$: distancia al arco, sector del cuerpo, bin del portero (0 = abierto) y $f = \text{facing_ok}$ ($|a_g| \leq 20^\circ$). Acciones: giros (no terminan el episodio) y cinco sectores de disparo; horizonte corto ($T_{\max} = 8$). Los postes usan la escala RoboCup 2D ($\pm 7,01$ m). Entrenamiento mixto 50/50 con/sin arquero; evaluación greedy separada (umbrales $> 75\%$ abierto, $> 50\%$ con portero). El ruido del tiro crece si el cuerpo está mal alineado: de ahí la necesidad de alinear antes de patear.

2.5. Pase y posesión 2v1

Atacante + compañero vs defensor *estocástico* (persigue el balón con velocidad aleatoria). Estado $s = (d_c, a_c, d_d, a_d, h)$: distancia/ángulo al compañero y al defensor (bins polares) y $h = 1$ si el atacante controla el balón. Macros: pase, drible, giro y ALEJARSE. Éxito conjunto: posesión ≥ 50 pasos y ≥ 3 pases. Detalles: pase moderado (no +30), posesión densa (+1,2/paso) y ALEJARSE. El stun post-pase es opcional (parámetro `defender_stun_on_pass`; por defecto 0 tras ablación).

3. Qué entrenamos

Cuatro configuraciones por tarea:

- Monte Carlo Control On-Policy (First-Visit) con $\varepsilon = 0,1$ fijo y con $\varepsilon_k = \max(0,05, 1,0 \cdot 0,998^k)$.
- Q-Learning ($\alpha = 0,1$) con los mismos esquemas de exploración.

`run_all_tasks.py` exporta curvas, trays y métricas. `generate_tray_sets.py` produce variantes exitosas con distintas semillas (para no depender de un único episodio “afortunado”).

4. Resultados: panorama

Tarea	Mejor corrida	Qué observamos
Pursuit	QL + ε decay (100 %)	≈ 31 pasos
Dribbling	QL + ε decay (100 %)	Umbral 30 m
Shooting	MC + ε fijo	Open 98 % / GK 83 %
Passing	MC + ε fijo (93 %)	Pos. ≈ 51 , stun= 0

Tabla 3: Mejor configuración por tarea (últimos 100 episodios; tiro con eval greedy separada).

Tiro y pase fueron los que más dependieron de alinear R (y la dinámica) al criterio del enunciado, no solo de subir G_0 .

5. Zoom en persecución

Configuración	Retorno G_0	Pasos	Éxito
MC + ε decay	148,8	38,4	95 %
MC + ε fijo 0,1	21,0	80,0	53 %
QL + ε decay	166,1	31,4	100 %
QL + ε fijo 0,1	157,7	41,1	100 %

Tabla 4: Pursuit con $d_b \in [5, 40]$ m (últimos 100 episodios).

Con distancias iniciales largas, MC + ε fijo queda corto: first-visit promedia retornos muy distintos (timeout vs captura) y, si la exploración no se apaga, “ensucia” pares (s, a) . Q-Learning, al bootstrapear, es más robusto aquí.






Figura 1: Pursuit—aprendizaje: G_0 , tasa de éxito y pasos (MA-50).



(a) V^* y π^* (mejor config.)



(b) Trayectoria greedy canónica

Figura 2: Pursuit—política tabular y un episodio greedy típico (“alineal y empujar”).

6. Drible

El shaping (acercarse a la meta + castigo por perder posesión) basta para una política estable; dash con balón cerca rinde más que patadas fuertes.




Figura 3: Drible—aprendizaje: las cuatro configs terminan altas; QL+ ϵ decay es la más ágil (≈ 39 pasos, 100 %).




Figura 4: Drible—trayectorias greedy (avance > 30 m con posesión).

7. Tiro

El cambio clave fue permitir alineación antes del disparo. MC + ϵ fijo alcanza 98 % abierto y 83 % con portero en eval greedy (umbrales 75 %/50 %).





Figura 5: Tiro—aprendizaje bajo mixto open/GK (episodios cortos: alinear y patear).



Arco abierto



Con portero

Figura 6: Tiro—trayectorias greedy canónicas (open / GK).

8. Pase 2v1

Premiar cada pase con $+30$ inflaba G_0 pero no la posesión. Tras rebalancear (posesión densa, pases moderados, ALEJARSE), el criterio estricto es aprendible. Con defensor estocástico y $\text{stun}=0$ (config adoptada), MC + ϵ fijo alcanza $\approx 93\%$ de éxito estricto.




Figura 7: Pase 2v1—curvas de aprendizaje ($\text{stun}=0$). QL infla G_0 con muchos pases; el éxito estricto favorece a MC.

El stun post-pase **no** está en el enunciado: era un colchón nuestro. Una ablación (3000 eps, MC/QL, ϵ fijo) muestra que se puede **quitar** sin romper el aprendizaje; subir mucho la velocidad del defensor sí lo degrada.

Con $\text{stun}=0$ el rastro del defensor es mucho más largo; con $\text{stun}=3$ a menudo apenas se mueve (misma seed abajo).







Figura 8: Passing—éxito vs libertad del defensor (MC/QL, 3000 eps).



stun= 3 (disp. corta)



stun= 0 (disp. larga)



Canónica adoptada (stun= 0)



Variante stun= 0

Figura 9: Pase—ablación visual del stun y trays con defensor libre (rastro rojo).

Config. defensor	MC éxito	QL éxito
stun= 3 (histórico)	97 %	85 %
stun= 1	97 %	90 %
stun= 0 (adoptado)	93 %	81 %
stun= 0, velocidad +25 %	77 %	65 %
stun= 0, velocidad +50 %	76 %	72 %

Tabla 5: Ablación de libertad del defensor (últimos 100 eps; seed 42). Adoptamos stun= 0 con velocidad base 0,18+0,10 U .

9. Conclusiones

Cumplimos la Fase 1: cuatro MDPs con discretización justificada, MC Control y Q-Learning, ε fijo vs decay, curvas, V^*/π^* , trayectorias y umbrales del enunciado.

- **Discretizar con criterio.** Bins polares anclados al kickable (0,8 m) y a conos de dash/giro; cada tarea extiende esa base (meta, GK, compañero/defensor).
- **Pipeline uniforme.** El mismo código de agentes/métricas sirve a las cuatro tareas si el contrato del env es homogéneo.
- **Exploración importa.** En persecución, MC con ε fijo no limpia timeouts en distancias largas; con decay sí. En tiro y pase, ε fijo ayuda a seguir muestreando acciones útiles.
- **No hay ganador único.** Persecución/drible (camino largo, shaping denso) $\rightarrow$ **QL** + ε **decay**. Tiro (ruido, pocas decisiones) y pase ($R \neq$ criterio del enunciado) $\rightarrow$ **MC** + ε **fijo**: el retorno episódico y la exploración constante estiman mejor kicks/macros; QL infla G_0 localmente (p. ej. spamear pases) con peor éxito estricto. El cuello de botella es la profundidad temporal o la alineación $R \leftrightarrow$ criterio.
- **Shaping amarrado al enunciado.** En pase, premiar pases sin posesión densa falló; rediseñamos R y, en ablación, quitamos el stun post-pase (colchón nuestro, no requisito del curso).
- **Límite del proxy.** Sin visión ruidosa ni estamina; revalidar en `rcssserver`. Fase 2: DQN/PPO y jerarquías sobre estas skills.

Referencias

- [1] R. S. Sutton and A. G. Barto, *Reinforcement Learning: An Introduction*, 2nd ed., MIT Press, 2018.
- [2] H. Kitano et al., “The RoboCup Soccer Server,” in *RoboCup-97*, Springer, 1998.
- [3] A. Y. Ng, D. Harada, and S. Russell, “Policy invariance under reward transformations,” in *ICML*, 1999.